Lecturer Note

Mata Kuliah

Data Warehousing and Data Mining

Week 1

BAB 1: KONSEP DASAR DAN RANCANGAN DATA WAREHOUSING

Capaian Pembelajaran Bab (Sub-CPMK 1): *Mahasiswa mampu menjelaskan konsep dasar Data Warehouse, arsitektur, Operational Data Store (ODS), proses Extraction Transformation Loading (ETL), serta peran dan kategori metadata*.

1.1 Pengertian dan Karakteristik Data Warehouse

Dalam era transformasi digital, volume data yang dikumpulkan oleh organisasi berkembang sangat pesat. Permasalahan utama yang dihadapi organisasi saat ini bukanlah kekurangan data, melainkan bagaimana mengekstraksi pengetahuan dan nilai bisnis dari tumpukan data tersebut. **Data Warehouse (DW)** hadir sebagai fondasi basis data terpusat yang dirancang khusus untuk mendukung proses pengambilan keputusan dan analisis manajemen.

Menurut pakar arsitektur basis data **William H. Inmon**, *Data Warehouse* didefinisikan sebagai:

"A subject-oriented, integrated, time-variant, and nonvolatile collection of data in support of management's decision making process."

Berdasarkan definisi tersebut, terdapat **empat karakteristik utama** yang membedakan *Data Warehouse* dari sistem basis data tradisional:

1. **Berorientasi Subjek (*Subject-Oriented*)**: Data disusun berdasarkan subjek utama organisasi (seperti *pelanggan, produk, penjualan, dan pemasok*), bukan berpatokan pada proses aplikasi atau transaksi harian.
2. **Terintegrasi (*Integrated*)**: Data dibangun dengan menggabungkan berbagai sumber data heterogen (seperti basis data relasional, berkas teks, dan catatan transaksi *online*). Proses pembersihan dan integrasi dilakukan untuk menjamin konsistensi penamaan, struktur pengodean, dan ukuran atribut.
3. **Bervariasi Waktu (*Time-Variant*)**: Data disimpan dalam rentang perspektif historis (misalnya 5 hingga 10 tahun terakhir). Setiap struktur kunci dalam *Data Warehouse* mengandung elemen waktu secara eksplisit maupun implisit.
4. **Non-Volatile (*Nonvolatile*)**: *Data Warehouse* berada pada media penyimpanan terpisah dari basis data operasional. Data yang telah dimuat bersifat permanen dan tidak mengalami perubahan transaksi secara *real-time*; operasi utama yang terjadi hanyalah pemuatan awal data (*initial loading*) dan akses pemanggilan data (*read-only access*).

1.2 Perbedaan OLTP dan OLAP

Untuk memahami fungsi *Data Warehouse*, penting untuk membedakan antara sistem **On-Line Transaction Processing (OLTP)** dan **On-Line Analytical Processing (OLAP)**.

- **OLTP** berfokus pada pemrosesan transaksi harian yang bersifat operasional (seperti penjualan kasir, perbankan, registrasi, dan penggajian).
- **OLAP** berfokus pada analisis data historis dan penyajian informasi multidimensi guna mendukung analisis keputusan oleh para manajer dan analis (*knowledge workers*).

Tabel 1.1 Komparasi Antara Sistem OLTP dan OLAP

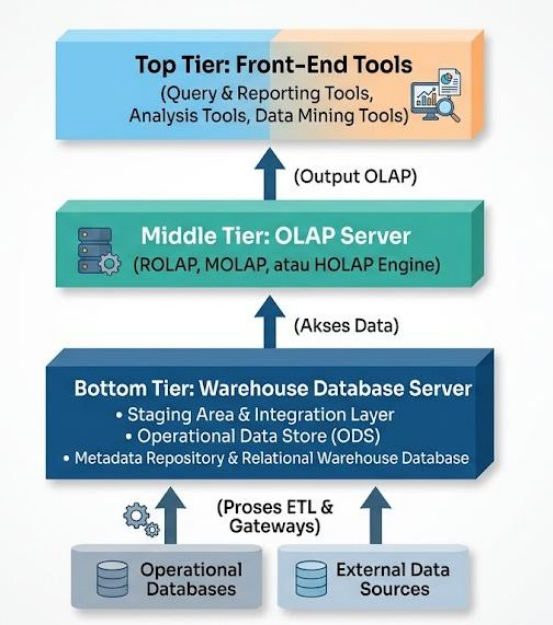
Fitur / Aspek	OLTP (*On-Line Transaction Processing*)	OLAP (*On-Line Analytical Processing*)
Karakteristik	Pemrosesan operasional harian	Pemrosesan informasi & analisis
Orientasi Sistem	Transaksi (*customer-oriented*)	Analisis pasar (*market-oriented*)
Pengguna Utama	Kasir, staf administrasi, DBA, praktisi IT	Manajer, eksekutif, dan analis data
Desain Basis Data	Berorientasi aplikasi / *Entity-Relationship* (ER)	Berorientasi subjek / Skema Bintang & Salju
Sifat Data	Data saat ini (*current*), rinci (*detailed*)	Data historis, teragregasi & tersimpul (*summarized*)
Pola Akses Data	Transaksi pendek, *read/write*, pembaruan rutin	Kueri kompleks, *scan* data luas, *mostly read-only*
Ukuran Basis Data	Megabyte (MB) hingga Gigabyte (GB)	Gigabyte (GB) hingga Terabyte (TB)

Mengapa Harus Memisahkan Data Warehouse dari Basis Data Operasional? Menjalankan kueri analisis OLAP yang kompleks langsung di atas basis data operasional (OLTP) akan menurunkan performa sistem transaksi secara drastis. Basis data operasional dioptimalkan untuk pencarian rekor individu dan transaksi cepat, sedangkan *Data Warehouse* dioptimalkan untuk pemrosesan agregasi dan pemindaian data berskala besar.

1.3 Arsitektur Data Warehouse dan Operational Data Store (ODS)

1. Arsitektur Tiga Tingkat (*Three-Tier Architecture*)

Secara umum, *Data Warehouse* mengadopsi arsitektur tiga tingkat:



Gambar 1 : *Data Warehouse* arsitektur tiga tingkat

- **Bottom Tier (Tingkat Bawah)**: Merupakan server basis data *warehouse* tempat penyimpanan data fisik. Tingkat ini dilengkapi *back-end tools* dan *gateways* (seperti ODBC, OLEDB, atau JDBC) untuk mengabstraksi dan mengekstrak data dari basis data operasional maupun sumber eksternal. Pada tingkat ini juga terdapat *staging area* dan *metadata repository*.
- **Middle Tier (Tingkat Tengah)**: Merupakan server OLAP yang memetakan struktur multidimensi ke pengguna. Server ini diimplementasikan menggunakan model **ROLAP** (*Relational OLAP*), **MOLAP** (*Multidimensional OLAP*), atau **HOLAP** (*Hybrid OLAP*).
- **Top Tier (Tingkat Atas)**: Merupakan antarmuka *front-end* yang menyediakan alat pelaporan (*query & reporting*), alat analisis bisnis, serta perkakas *Data Mining*.

2. Operational Data Store (ODS)

Operational Data Store (ODS) adalah area basis data logis sementara (*interim area*) yang digunakan sebelum data dimasukkan ke dalam *Data Warehouse*.

- Di dalam ODS, data dari berbagai sumber dikumpulkan, dibersihkan (*scrubbed*), diperiksa aturan bisnisnya, dan dihilangkan redundansinya.
- **Analogi Memori**: ODS dapat dianalogikan sebagai **memori jangka pendek** (*short-term memory*) karena hanya menyimpan data operasional terkini, sedangkan *Data Warehouse* dianalogikan sebagai **memori jangka panjang** (*long-term memory*) yang menyimpan data historis secara permanen.

3. Ragam Model Data Warehouse

- **Enterprise Warehouse**: Mengumpulkan seluruh informasi organisasi lintas fungsi dan bidang bisnis.
- **Data Mart**: Bagian terpisah dari *Data Warehouse* yang difokuskan pada satu subjek atau departemen spesifik (misalnya khusus *Data Mart Penjualan* atau *Data Mart Pemasaran*).

Data Mart terbagi menjadi *independent data mart* (bersumber langsung dari sistem operasional) dan *dependent data mart* (bersumber dari enterprise warehouse).

- **Virtual Warehouse**: Berupa kumpulan *views* di atas basis data operasional tanpa penyimpanan fisik terpisah.

1.4 Proses Extraction, Transformation, and Loading (ETL)

ETL merupakan alur kerja krusial untuk mengambil data dari berbagai sistem sumber operasional, mengubahnya sesuai kebutuhan analisis, dan memuatnya ke dalam *Data Warehouse* secara berkala.



Gamabr 2 : Proses Extraction, Transformation, and Loading

1. **Extraction (Ekstraksi Data)**:
    - Mengidentifikasi dan mengumpulkan data yang relevan dari berbagai basis data dan sistem aplikasi heterogen. Ukuran data yang diekstrak bervariasi mulai dari megabyte hingga gigabyte.
2. **Transformation (Transformasi Data)**:
    - Mengubah format data mentah agar sesuai dengan skema *Data Warehouse*. Proses ini meliputi pembersihan data (*cleaning*), standardisasi pengodean, penanganan nilai hilang, integrasi skema, serta pembuatan kunci pengganti (*surrogate key*) melalui proses *lookup*.
3. **Loading & Refreshing (Pemuatan & Penyesuaian)**:
    - Memuat data hasil transformasi ke dalam tabel fakta dan dimensi *Data Warehouse*. Proses ini melibatkan penyusunan indeks, pembaruan agregasi, serta penjadwalan *refresh* data berkala.

1.5 Metadata Repository dan Pengelolaannya

Metadata secara sederhana didefinisikan sebagai *"data mengenai data"* (*data about data*). Dalam sistem *Data Warehouse*, metadata berfungsi sebagai direktori dan *road map* yang memandu pengguna dan sistem untuk menemukan, memetakan, serta mengelola isi *Data Warehouse*.

Tiga Kategori Utama Metadata:

1. **Business Metadata**: Berisi definisi istilah bisnis, informasi kepemilikan data (*data ownership*), serta kebijakan perubahan aturan bisnis.
2. **Technical Metadata**: Berisi nama sistem basis data, nama tabel dan kolom, tipe data, batasan nilai (*constraints*), struktur kunci utama/asing (*primary/foreign keys*), serta informasi skema.
3. **Operational Metadata**: Berisi status aktualitas data (*currency of data*)—apakah data aktif, diarsipkan, atau dihapus—serta riwayat silsilah data (*data lineage*) yang mencatat proses migrasi dan transformasi yang telah diterapkan.

Peran Metadata Repository:

- Metadata Repository menyimpan deskripsi skema *Data Warehouse*, aturan pemetaan (*mapping rules*) dari lingkungan operasional ke *Data Warehouse*, algoritma agregasi, profil performa sistem, serta riwayat *refresh*.

Rangkuman Bab 1

- *Data Warehouse* adalah repositori data terpusat yang bersifat *subject-oriented, integrated, time-variant,* dan *nonvolatile* untuk mendukung pengambilan keputusan.
- Sistem OLTP melayani transaksi operasional harian (*read/write*), sedangkan sistem OLAP melayani kueri analisis multidimensi historis (*read-only*).
- Arsitektur *Data Warehouse* terdiri dari tiga tingkat: *Bottom Tier* (server database & ODS), *Middle Tier* (server OLAP), dan *Top Tier* (front-end tools & Data Mining).
- Proses ETL (*Extraction, Transformation, Loading*) adalah tahapan utama dalam mengintegrasikan data heterogen ke dalam *Data Warehouse*.
- Metadata bertindak sebagai direktori yang mencatat informasi bisnis, teknis, dan operasional seluruh objek dalam *Data Warehouse*.

1.7 Latihan Soal dan Diskusi

1. **Jelaskan** perbedaan mendasar antara sistem OLTP dan OLAP ditinjau dari aspek orientasi pengguna, sifat data, dan pola akses kueri!
2. **Mengapa** proses analisis OLAP tidak direkomendasikan untuk dijalankan langsung di atas basis data operasional (OLTP)?
3. **Uraikan** empat karakteristik utama *Data Warehouse* menurut W. H. Inmon!
4. **Jelaskan** peran *Operational Data Store* (ODS) dalam arsitektur *Data Warehouse* dan bagaimana hubungannya dengan proses ETL!
5. **Sebutkan dan jelaskan** tiga kategori metadata dalam *Data Warehouse* beserta contoh informasinya masing-masing!